

U-Net 기반 아키텍처를 활용한 울혈성 심부전 환자 폐부종 진단 방법론 연구

권다운*

Exploring Diagnostic Methodology for Pulmonary Edema Diagnosis in Patients with Congestive Heart Failure Using U-Net Based Architecture

Da-Woon Kwon*

*Undergraduate Student, Department of IT Convergence, University of Ulsan, Ulsan, 44610 Korea

요 약

폐부종과 이로 인한 호흡곤란 증상은 울혈성 심부전 환자에게 찾아오는 가장 흔한 증상 중 하나이며, 환자의 폐부종 유무에 따라 복잡한 임상 관리 결정이 달라진다. 울혈성 심부전은 급성으로 나타날 수 있는 병태생리학적 상태인 점에서 신속한 진단과 임상 관리 결정이 요구된다. 이에 따라 본 연구에서는 MIMIC-CXR-JPG 데이터 세트를 바탕으로 울혈성 심부전 환자의 흉부 방사선 검사를 통해 폐부종의 유무를 진단하는 모델을 구축하였다. 또한, U-Net 기반 아키텍처를 사용하여 폐 영역 분할 후, 분할 전 이미지와 결합하여 폐 영역에 대한 집중도를 높이고, DenseNet121과 VGG16을 사용하여 분할하지 않은 이미지와 비교 실험을 통해 더 나은 성능을 보임으로써 전처리에 대한 방법론을 제시한다. 나아가 본 논문에서 제시하는 방법론을 발전시켜 다양한 질환에 대한 전처리로 활용될 수 있을 것으로 보인다.

ABSTRACT

The symptom of dyspnea due to pulmonary edema is one of the most common presentations in patients with congestive heart failure (CHF), where clinical management decisions vary based on the presence or absence of pulmonary edema. CHF, being a pathophysiological state that can manifest acutely, demands prompt diagnosis and clinical management decisions. Therefore, in this study, we constructed a model to diagnose the presence of pulmonary edema in patients with congestive heart failure using chest radiographs from the MIMIC-CXR-JPG dataset. Furthermore, we propose a methodology for preprocessing by utilizing a U-Net-based architecture for lung segmentation, enhancing focus on the lung regions by combining segmented and original images, and conducting comparative experiments with DenseNet121 and VGG16 on unsegmented images, demonstrating superior performance. Moreover, we suggest that the methodology presented in this paper could be further developed and applied to preprocessing for various conditions.

키워드 : 시맨틱 분할, 흉부 방사선 검사, 울혈성 심부전, 폐부종

Keywords : Semantic Segmentation, Chest X-Ray, Congestive Heart Failure, Pulmonary Edema

Received 29 January 2019,

Revised 29 March 2019,
(출판사에서작성)

Accepted 21 April 2019

* Corresponding Author Da-Woon Kwon(E-mail:dobylove01@gmail.com, Tel:+82-010-9686-0814)

Undergraduate Student, Department of IT Convergence, University of Ulsan, Ulsan, 44610 Korea

Open Access <http://doi.org/10.6109/jkiice.2019.23.1.399>

pISSN:2234-4772

© This is an Open Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License(<http://creativecommons.org/licenses/by-nc/3.0/>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.
Copyright © The Korea Institute of Information and Communication Engineering.

I. 서 론

울혈성 심부전(Congestive Heart Failure, CHF)이란 복합적인 원인으로 심장이 신체조직이나 기관에 필요한 혈액을 공급할 수 없는 병태생리학적 상태를 말한다. 이로 인해 혈관 내부의 압력이 증가함에 따라 폐정맥의 정수압이 상승하고, 혈관 밖으로 액체가 폐의 간질과 폐포로 이동하여 과도하게 축적되어 발생하는 질환을 폐부종(Pulmonary Edema)이라 한다[1-2]. 울혈성 심부전은 급성으로 발생하거나 악화할 수 있고, 폐부종을 비롯한 여러 동반 질환의 유무에 따라 임상 관리 결정이 달라진다. 이에 따라 의료진들은 환자들을 진단함에 추후 임상 관리에 대해 고려해야 하며 보다 빠른 진단이 요구된다.

최근 딥러닝의 발전은 많은 분야에 응용이 되어오고 있으며, 의료 분야에서는 진단 보조 및 발병 예측에서 딥러닝을 활용한 연구들이 이루어지고 있다. 특히, 환자의 CT, X-Ray, MRI 등 이미지 데이터를 활용한 연구 사례들은 주목하는 질환, 촬영 방향, 의료진의 진단 과정 등 다양한 변수들을 고려해야 하며, 이에 대한 명확한 방법론을 제시하기에는 어려움이 있다. 하지만 D. Zhang et al.[3]는 의료진의 진단 과정에 주목하여 뇌 MRI에서 뇌종양을 진단할 때, 뇌종양의 핵심이 되는 Enhancing Tumor를 우선으로 시맨틱 분할을 하고, 이 분할을 이어지는 추론에 사용하여 Tumor Core, Whole Tumor를 반복되는 과정 안에서 모두 분할하여 우수한 성능을 보인다.

따라서 본 연구에서는 흉부 방사선 검사에서 울혈성 심부전 환자의 폐부종 진단을 할 때, 의료진의 진단 과정에 착안하여 폐 영역에 대한 시맨틱 분할을 사용한다. 시맨틱 분할을 하기 위해 U-Net, SA U-Net, U-Net++ 아키텍처를 활용하여 동일한 조건에서 학습시켜 정확도, F1-Score, AUC, MCC를 비교하여 성능이 우수한 모델을 선정했다. 분할된 폐 영역에 대해서 기존 흉부 방사선 검사와 결합하는 방식에 대한 2개의 방법, 분할된 폐 영역만을 사용하는 방법, 그리고 기존 방사선 검사 이미지의 전처리 유무에 따른 2개의 방법으로 총 5개 유형의 데이터를 통해 분류 실험을 진행했다. 5개의 분류 실험을 비교하기 위해 채택한 모델은 DenseNet121과 VGG16이며, 2가지 클래스 (Normal, Abnormal)로 분류한 결과를 비교하였을 때, 분할된 폐

영역과 기존 방사선 검사와 결합하는 방법이 가장 좋은 성능임을 보였다. 이를 통해 이미지 데이터를 사용해 특정 질환을 분류하는 것에 있어 시맨틱 분할 기술을 응용할 수 있는 방법을 제안했다.

본 논문의 구성은 다음과 같다. 2장에서는 연구에서 사용한 MIMIC-CXR-JPG 데이터 세트와 확장 데이터 세트를 활용하여 최종적으로 사용한 데이터 세트를 설명하였고, 3장에서는 사용된 시맨틱 분할 모델의 구조를 기술하고, 학습 결과를 비교했다. 4장에서는 시맨틱 분할된 폐 영역 데이터와 원본 이미지 데이터를 결합하는 방법을 설명하였다. 5장에서는 5가지 유형의 데이터를 DenseNet121과 VGG16을 통해서 학습한 결과를 비교하였고, 마지막으로 6장에는 비교 분석을 통한 결론 및 향후 연구를 기술하였다.

II. 데이터 세트 구축

본 연구에서 사용한 데이터는 MIMIC-CXR-JPG와 확장 데이터 세트로 폐 영역 분할 데이터를 제공하는 Chest X-ray Dataset with Lung Segmentation과 폐부종의 중증도 데이터를 제공하는 Pulmonary Edema Severity Grades Based on MIMIC-CXR[4-6]을 사용한다. 해당 연구의 기반이 되는 MIMIC-CXR-JPG 데이터 세트는 65,379명의 환자의 흉부 방사선 검사 데이터를 제공한다.




Fig. 1 Frontal view and lateral view of chest X-ray images from MIMIC-CXR-JPG dataset

개발 환경의 자원에 따라 하위 폴더 p10부터 p15에 해당하는 39,139명의 환자 데이터를 사용한다. 파생 데이터 세트를 통해 시맨틱 분할 데이터 가용 여부, 울혈성 심부전 환자, 폐부종 중증도 표시 여부를 고려하여

데이터 세트를 구축했다. 폐부종에 대한 중증도는 (0: Normal, 1: Vascular congestion, 2: Interstitial edema, 3: Alveolar edema)으로 나뉜다. 정상을 제외한 나머지 클래스는 모두 폐부종을 나타내는 클래스로 정상 혹은 비정상을 가리기 위해 1, 2, 3에 해당하는 클래스를 하나의 클래스(1: Abnormal)로 다시 표시하여, 이진 분류로 실험했다. 또한, 촬영 방식이 전방 촬영(그림 1(a)), 측면 촬영(그림 2(b)) 2가지 방법으로 제공되기 때문에 모델 학습에 있어서 데이터의 일관성을 위해 전방 촬영 데이터만을 다루어 진행하였다. 결론적으로, 본 연구에서 사용하는 데이터는 총 4,198개의 데이터를 활용했다. 80%(3,358)를 훈련 세트로 사용하고, 20%(840)를 테스트 세트로 분류했다. 그림 2는 위 데이터 세트 구축 과정을 요약하여 보여준다.

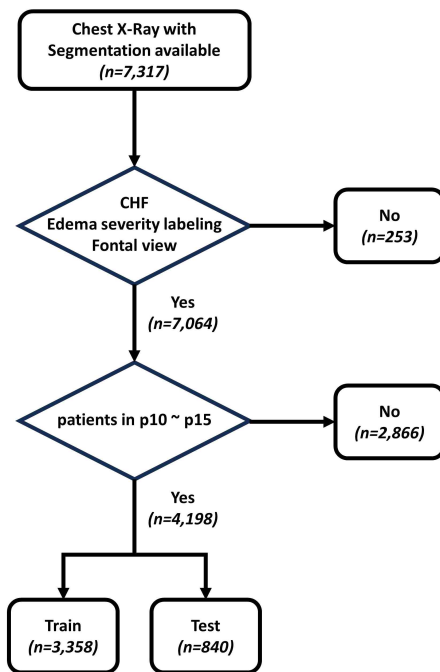


Fig. 2 The detailed process of data extraction

III. 시맨틱 분할 모델 성능 비교

3.1 U-Net

U-Net[7]은 의료 영상 분할을 위해 고안된 모델이며, 기존의 FCN(Fully Convolutional Network)을 토대로

확장한 개념에 Skip Connection을 추가하여 시맨틱 분할을 진행한다. 수축 경로는 Down Sampling 기법을 통해서 이미지의 특징 정보를 추출한다. 확장 경로에서는 이와 반대로 Up-Sampling 기법을 통해 특성맵을 시맨틱 분할을 하기 위한 이미지의 크기로 복원시킨다. Skip Connection은 수축 경로의 같은 층에 해당하는 확장 경로에 특성맵을 전달하여 해당 층의 공간적인 정보를 보존한다. 전달된 특성맵은 확장 경로의 특성맵과 결합함으로써 이미지의 공간적인 정보와 특성이 추출된 정보를 한 번에 사용하여 시맨틱 분할에 기여하는 것이 특징이다. U-Net의 경로에 따른 각 층에는 합성곱 층, 배치 정규화, 활성화 함수를 두 번씩 사용한 합성곱 블록을 통해 모델의 복잡성을 증가시킨다. 표 1은 U-Net의 수축 경로에서의 합성곱 블록 구성을 나타낸다.

Table. 1 Convolutional block of U-Net contracting path

Input image (1×224×224)			
Layer		Output shape	
Convolution		64×512×512	
Batch Normalization		64×512×512	
ReLU		64×512×512	
Convolution		64×512×512	
Batch Normalization		64×512×512	
ReLU		64×512×512	
Down sampling	Skip connection	64×256×256	64×512×512

3.2 SA U-Net

SA U-Net[8-9]은 U-Net 기반 모델로 Structured Dropout Convolutional Block과 Spatial Attention Module(SAM)을 사용하여 U-Net의 과적합 문제를 해결하는 모델이다[7]. Structured Dropout Convolutional Block에 사용되는 DropBlock과 Dropout의 주된 차이점은 랜덤하게 픽셀을 독립적으로 제거하는 것이 아닌 특성맵의 공간 차원 정보임을 고려하여 연속적인 영역을 제거하는 것이다. DropBlock을 기존 합성곱 블록에서 합성곱 층과 배치 정규화 층 사이에 넣어 설계하여 Structured Dropout Convolutional Block을 구성한다. SAM은 특성맵의 각 맵들 사이에 공간적인 관계성을 추출하여 Spatial Attention Map을 생성한다. Spatial

Attention Map을 생성하기 위해서 채널에 해당하는 축을 따라 max-pooling과 average-pooling을 연산하고, 연산한 두 특성맵을 합성곱하여 생성한다. SAM은 수축 경로와 확장 경로를 잇는 브릿지에서 사용한다.

3.3 U-Net++

U-Net++[10]는 U-Net과 유사한 방식을 사용하여 시맨틱 분할을 진행하지만, Skip Connection을 기존의 방식에서 Up-Sampling 기법을 추가적으로 사용하여 각 층에 상응하는 수축 경로에서 확장 경로로 보낼 뿐만 아니라 수축 경로의 위층에 해당하는 확장 경로의 층에 Skip Connection을 하여 모델의 전반적인 구조에 복잡성을 증가시켜 모든 층에서 특성맵을 연산할 수 있도록 한다. 또한, U-Net++는 새롭게 설계된 Skip Connection에 대해 시맨틱 분할의 결과를 내는 Deep Supervision 방식을 제안한다. 시작 층에 해당하는 모든 Skip Connection에 대한 특성맵의 평균값을 사용하는 Accurate Mode와 기존 U-Net과 같은 방식과 같이 결과를 도출하는 Fast Mode를 사용할 수 있다.

3.4 시맨틱 분할 모델 학습 및 비교 실험

시맨틱 분할을 위해 그림 2와 같이 4,198개의 학습 데이터를 3,358개의 훈련 세트, 840개의 테스트 세트로 진행하였다. 또한, 시맨틱 분할 마스크 데이터를 제공하는 확장 데이터 세트에서는 224x224 크기의 데이터 형식을 제공한다. 이에 따라 원본 이미지의 사이즈를 조절하였다. 학습을 위해 사용한 손실 함수는 Dice loss로 식 1과 같다. Dice loss는 시맨틱 분할 분야에서 범용적으로 사용되는 손실 함수로 실제값과 예측값의 유사도를 비교하는 함수이다. 실제 영역 A 와 예측 영역 B 가 정확히 같다면 1, 완전히 다르다면 0을 반환한다.

$$Dice\ Loss = \frac{2 \times (|A| \cap |B|)}{|A| + |B|} \quad (1)$$

optimizer는 Adam을 사용하였으며, 초기 학습률을 $1e-4$, decay step은 5, decay rate는 0.1로 설정하여 실험을 진행하였다. 또한, 활성화 함수는 폐 영역의 여부를 고려하기 때문에 sigmoid로 설정하였으며, 모든 모델의 epoch는 50으로 설정한 후 실험을 진행하였다.

SA U-Net의 경우 DropBlock에서 랜덤하게 제거하

는 특성맵의 사이즈를 특성맵의 10%, 20%로 갖도록 나누어서 학습하였고, U-Net++의 경우에는 Deep supervision을 fast mode, accurate mode로 나누어서 학습을 진행하였다. 평가지표는 정확도, F1-Score, AUC, MCC를 통해 비교했다. 표 2는 동일한 학습 환경에서 5개의 학습한 모델로 테스트 세트에 대해 시맨틱 분할을 한 결과를 나타낸다.

Table. 2 Semantic segmentation result

Model	Accuracy	F1-Score	AUC	MCC
U-Net	94.67%	0.9808	0.9749	0.9729
SA U-Net (10%)	93.98%	0.9684	0.9695	0.9554
SA U-Net (20%)	93.85%	0.9660	0.9613	0.9521
U-Net++ (fast)	94.60%	0.9795	0.9720	0.9711
U-Net++ (accurate)	94.59%	0.9793	0.9722	0.9708

가장 정확도가 높은 모델은 U-Net으로 94.67%의 정확도를 기록했고, 가장 정확도가 낮은 모델은 특성맵의 20%를 랜덤하게 제거하는 SA U-Net으로 93.85%의 정확도를 기록하였다. 전반적으로 U-Net이 높은 성능을 보임에 따라 본 연구의 전체 구조에서 사용한 시맨틱 분할 모델은 U-Net이다.

IV. 폐 영역 분할 데이터 결합 방법

4.1 가우시안 필터와 이미지 블렌딩 방법

가우시안 필터(Gaussian filter)는 가우시안 분포(Gaussian distribution) 함수를 근사하여 생성한 필터 마스크를 사용하는 필터링 기법으로 이미지 처리에서 노이즈를 제거하기 위해 사용되는 필터 중 하나이다. 노이즈를 제거함으로써 이미지의 세부 정보를 보존하여 전처리 기법으로 사용된다. 가우시안 필터는 주위 픽셀로부터 2차원 가우시안 함수를 필터 커널로 사용한다. 가우시안 함수는 식 2와 같다. $G(x, y)$ 는 가우시안 함수의 값이고, (x, y) 는 2차원 특성맵 내의 픽셀 좌표를 의미한다. e 는 자연 상수이고, σ 는 가우시안 분포의 표준편차이다. 가우시안 분포의 표준편차가 커짐에 따라 (x, y) 를 중심으로 가까운 픽셀이 더 많은 가중치를 가지게 되고, 반대의 경우 중심과 떨어진 픽셀도 유효한

가중치를 가지게 된다. 필터 커널은 이미지에서 특정 픽셀 주변에 적용되는 가중치 행렬을 의미하는데, 이 행렬은 이미지의 각 픽셀을 중심으로 설정된 윈도우 크기에 따라 달라진다.

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (2)$$

이미지 블렌딩(Image blending)은 이미지를 서로 합칠 때 가중치를 두어 합치는 방법이다. 수식은 식 3과 같다. $g(x)$ 는 블렌딩을 한 결과를 의미하며 $f_1(x)$, $f_2(x)$ 은 합치는 각 이미지를 의미한다. α 를 통해 두 이미지의 기여도를 결정하여 픽셀 간의 합 연산을 통해 블렌딩을 한다.

$$g(x) = (1 - \alpha)f_1(x) + \alpha f_2(x) \quad (3)$$




Fig. 3 Original chest X-ray image(a), gaussian filtered and blended chest X-ray image(b)

가우시안 필터와 블렌딩을 통해 이미지의 노이즈를 제거하고, 폐 영역에 대한 집중도를 높이도록 했다. 가우시안 필터를 표준편차 σ 가 1인 표준 정규 분포를 따르게 하여 필터 커널의 사이즈는 3으로 원본 이미지에 적용했다. 블렌딩의 α 값을 0.2로 할당하여 가우시안 필터를 적용한 원본 이미지와 폐 영역 이미지를 2:8의 비율로 혼합했다. 필터가 적용된 후에 이미지가 블렌딩되었기 때문에 폐 영역도 노이즈 제거의 효과를 가지게 했다. 해당 데이터 처리 과정을 거친 이미지는 그림 3과 같다.

4.2 가우시안 필터의 관점 재해석 및 병합 방법

가우시안 필터는 노이즈 제거라는 효과를 가지고 있

으나 시각적으로 표현하였을 때는 흐린 효과(Blurring)를 초래한다. 필터 커널을 통해 주위 픽셀을 참고하여 필터링하는 과정은 폐부종을 진단하는 것에 있어서 폐 혈관의 음영 부분을 의도와 달리 증감시키는 원인이 된다. 이에 따라 가우시안 필터에 대한 관점을 노이즈 제거가 아닌 흐린 효과로 해석하여 추가적인 방법을 고안했다. 원본 이미지에 대한 가우시안 필터는 4.1절과 같은 방법으로 적용했다. 이미지 블렌딩과 반대로 폐 영역에 대한 각 픽셀을 고정적으로 사용하기 위해 필터링이 된 원본 이미지의 폐 영역을 제거하고, 시맨틱 분할한 폐 영역을 병합하는 방법을 고안했다. 그림 4는 가우시안 필터가 적용되고, 폐 영역이 제거된 원본 이미지(그림 4(a)), 폐 영역 분할 이미지(그림 4(b)), 그리고 병합된 이미지(그림 4(c))를 나타낸다.




Fig. 4 Image filtered with gaussian, removing the lung area(a), image segmented into lung regions(b), result image merged with (a) and (b)(c)

V. 폐부종 분류 실험

5.1 불균형 데이터 세트

일반적으로 정상 혹은 특정 질환 클래스로 분류되는 의료 데이터 세트의 특징은 클래스의 불균형 문제를 늘 다루고 있다. 이와 관련하여 언더샘플링, 데이터 증강과 같은 기법들이 제안되고 있다. 본 연구에서 사용한 데이터 세트 또한 정상 환자 1,735명, 폐부종 환자 2,463명으로 구성되어 불균형 문제가 있다(그림 5). 이에 따

라 본 연구의 분류 실험에서 사용하는 손실 함수는 가중치 이진 교차 엔트로피 손실 함수(Weighted binary cross-entropy function)이다. 수식은 식 4와 같다. 이진 교차 엔트로피 손실 함수를 확장한 개념으로 차이점은 각 클래스에 대한 가중치의 유무이다. 가중치 w_i 를 각 클래스에 대한 서로 다른 가중치를 곱 연산함으로써 본 연구에서는 클래스 불균형 문제를 해결하였다.

$$L(y, \hat{y}) = -\frac{1}{N} \sum_{i=1}^N w_i [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (4)$$




Fig. 5 The class difference between 'Normal' and 'Abnormal'

5.2 각 실험에 대한 데이터 처리 방법

4장에서 제시한 폐 영역에 대한 데이터 결합 방법 2가지와 원본 이미지를 단독으로 사용하는 방법을 비교하기 위해 본 연구에서는 5가지의 실험을 진행했다. 실험에서 사용한 데이터 처리 방법은 다음과 같다.

실험 1) 원본 이미지에 가우시안 필터 적용 + 폐 영역 이미지 블랜딩, 4.1절의 방법과 같다.

실험 2) 원본 이미지에 가우시안 필터 적용, 폐 영역 부분 제거 + 폐 영역 이미지 병합, 4.2절의 방법과 같다.

실험 3) 폐 영역 이미지를 단독 사용했다.

실험 4) 원본 이미지를 단독 사용했다.

실험 5) 원본 이미지에 가우시안 필터를 적용했다.

또한, 히스토그램 평탄화[11] 전처리를 통해 각 픽셀의 분포를 평탄화하여 선명도를 높이는 과정을 거쳤다. 각 실험에 대한 데이터 처리 방법을 시각화한 것은 그림 6과 같다.

5.3 DenseNet121, VGG16를 통한 학습

본 연구에서 분류 실험을 위해서 DenseNet121[12]과 VGG16[13] 모델을 사용했다. DenseNet121은 VGG16와 비교하여 상대적으로 깊은 층의 신경망 구조이고, 실험 과정에서도 DenseNet121을 VGG16에 비해 상대적으로 복잡한 과정들을 거치도록 하여 제안하는 방법론에 대해 일반화가 성립되는지 관찰하도록 했다. 두 모델 모두 ImageNet-1K 데이터 세트가 사전 학습된 모델을 전이 학습시켰다. 또한, 입력층의 입력 채널 수를 흑백 채널에 맞게 기존의 합성곱 층을 새로운 합성곱 층으로 새로 할당을 하고, 이진 분류라는 특성에 맞게 출력층에 출력 뉴런을 하나로 갖는 완전 연결 층을 추가했다. DenseNet121은 모델을 구성하는 모든 층의 학습을 하도록 했고, VGG16은 모델 프리징(Model freezing)을 통해 수정한 입력층과 출력층만 학습하도록 했다. 또한, 이미지 사이즈를 DenseNet121은 224x224, VGG16은 64x64로 다르게 학습했다.

4,198개의 학습 데이터를 3,358개의 훈련 세트, 840개의 테스트 세트로 나누어 학습했다. optimizer는 Adam을 사용하였으며, 초기 학습률을 $1e-4$, decay step은 5, decay rate는 0.1로 설정하여 실험을 진행하였다. 활성화 함수는 정상 혹은 폐부종을 이진 분류하기 위해 sigmoid로 설정하였으며, DenseNet121 학습의 epoch는 100, VGG16 학습의 epoch는 30으로 할당하여 학습했다.




Fig. 6 Visualizations of data processing for each experiment

Table. 3 Performance comparison of DenseNet121 and VGG16 based on data processing methods

Model	Experiment	Accuracy	F1-Score	AUC	Sensitivity	Specificity	TP	FP	TN	FN
DenseNet121	1	75.00%	0.7965	0.8090	0.8204	0.6460	411	120	219	90
	2	73.93%	0.7932	0.7951	0.8383	0.5929	420	138	201	81
	3	73.45%	0.7890	0.7936	0.8323	0.5900	417	139	200	84
	4	73.57%	0.7815	0.7901	0.7924	0.6519	397	118	221	104
	5	74.05%	0.7846	0.7948	0.7924	0.6637	397	114	225	1104
VGG16	1	63.81%	0.7164	0.6628	0.7665	0.4484	384	187	152	117
	2	63.45%	0.7369	0.6570	0.8583	0.3038	430	236	103	71
	3	64.52%	0.7545	0.6659	0.8483	0.3451	425	222	117	76
	4	62.38%	0.6715	0.6681	0.6657	0.5929	323	138	201	178
	5	61.90%	0.7320	0.6501	0.8723	0.2448	437	256	83	64

손실 함수는 5.1절에서 언급한 불균형 데이터 세트의 문제점에 따라 가중치 이진 교차 엔트로피 함수를 사용했다. 5가지 실험에 대해 학습된 모델의 테스트 세트에 대한 성능은 정확도, F1-Score, AUC, 민감도, 특이도, TP(True Positive), FP(False Positive), TN(True Negative), FN(False Negative), 총 9가지의 평가지표를 통해 비교했다. 평가지표를 비교한 결과는 표 3으로 정리했다. 폐 영역을 고려한 실험 1, 2, 3의 결과가 실험 4, 5와 비교하였을 때, 상대적으로 좋은 성능을 보였다. 그리고, 원본 이미지에 대한 가우시안 필터 적용 및 폐 영역 이미지 블랜딩 방법을 통한 실험 1이 DenseNet121에서 75.00%, 폐 영역을 사용한 실험 3이 VGG16에서 64.52%로 가장 높은 정확도를 나타냈다. 따라서 본 논문에서 제안한 폐 영역을 고려한 폐부종 분류가 다른 결과에 비해 우수한 효과를 보임을 확인할 수 있었다.

VI. 결론 및 향후 연구

본 논문에서는 U-Net을 통해 폐 영역을 추출한 이미지를 원본 이미지와 결합하는 방법들을 고안했다. 제안한 방법들을 사용하여 정상과 폐부종 분류를 하기 위해 DenseNet121과 VGG16을 사용해 비교를 진행하였다. 폐 영역을 고려한 방법(실험 1)을 적용하였을 때, 75.00%, 63.81%의 정확도로 원본 이미지를 학습시킨 방법(실험 5)을 적용하였을 때, 74.05%, 61.90%의 정

확도보다 높은 것을 알 수 있었다.

본 실험을 통해서 폐부종을 진단하는 것에 있어 폐 영역에 대한 집중도를 높이는 방법이 더 좋은 것을 알 수 있었고, 이에 따라 폐부종뿐만 아니라 다양한 폐 질환을 분류하는 모델을 구축할 때, 본 연구에서 제안하는 방법이 활용되어 더 높은 성능을 보여줄 것으로 기대할 수 있다.

향후 연구에서는 본 논문의 실험 결과가 전반적으로 낮은 성능을 보였기 때문에 다양한 이미지 분류 모델을 사용하여 전반적인 성능을 높이는 실험들을 진행하고, 실험 1, 2의 방법을 토대로 더 효과적인 데이터 처리 방법을 고안할 계획이다.

REFERENCES

- [1] Ahmad Malik, Daniel Brito, Sarosh Vaqar, and Lovely Chhabra. "Congestive Heart Failure," Treasure Island (FL): StatPearls, 2023 [Internet]. Available: <https://www.ncbi.nlm.nih.gov/books/NBK430873/>.
- [2] Maria Barile, "Pulmonary Edema: A Pictorial Review of Imaging Manifestations and Current Understanding of Mechanisms of Disease," *European Journal of Radiology Open*, vol. 7, pp. 100274, Oct. 2020, DOI: 10.1016/j.ejro.2020.100274.
- [3] Dingwen Zhang, Qiang Zhang, Jungong Han, Junwei Han, Yizhou Wang, Yizhou Wang, and Yizhou Wu, "Exploring Task Structure for Brain Tumor Segmentation From

- Multi-Modality MR Images," *IEEE Transactions on Image Processing*, vol. 29, pp. 9032-9043, Sep. 2020, DOI: 10.1109/TIP.2020.3023609.
- [4] Alistair E. W. Johnson, Tom J. Pollard, Nathaniel R. Greenbaum, Matthew P. Lungren, Chih-ying Deng, Yifan Peng, Zhiyong Lu, Roger G. Mark, Seth J. Berkowitz, and Steven Horng, "MIMIC-CXR-JPG, a large publicly available database of labeled chest radiographs," arXiv, 2019 [Online]. Available: <https://arxiv.org/abs/1901.07042>
- [5] Wimukthi Indeewara, Mahela Hennayake, Kasun Rathnayake, Thanuja Ambegoda, and Dulani Meedeniya. (2023, February) "Chest X-ray Dataset with Lung Segmentation" (version 1.0.0). *PhysioNet* [Online]. Available: <https://doi.org/10.13026/9cy4-f535>.
- [6] Ruizhi Liao, Geeticka Chauhan, Polina Golland, Seth Berkowitz, and Steven Horng. (2021, February) "Pulmonary Edema Severity Grades Based on MIMIC-CXR" (version 1.0.1). *PhysioNet* [Online]. Available: <https://doi.org/10.13026/rz5p-rc64>.
- [7] Olaf Ronneberger, Philipp Fischer, and Thomas Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," arXiv, 2015 [Online]. Available: <https://arxiv.org/abs/1505.04597>.
- [8] C. Guo, M. Szemenyei, Y. Yi, W. Wang, B. Chen and C. Fan, "SA-UNet: Spatial Attention U-Net for Retinal Vessel Segmentation," *International Conference on Pattern Recognition*, pp. 1236-1242, May. 2021, DOI: 10.1109/ICPR48806.2021.9413346.
- [9] Ghiasi, Golnaz, Tsung-Yi Lin, and Quoc V. Le. "Dropblock: A regularization method for convolutional networks," *Advances in neural information processing systems* 31 (2018).
- [10] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, and Jianming Liang. "Unet++: A nested u-net architecture for medical image segmentation." *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support: 4th International Workshop, DLMIA 2018, and 8th International Workshop, ML-CDS 2018, Held in Conjunction with MICCAI 2018*, vol. 11045, pp. 3-11, Sep. 2018, DOI: 10.1007/978-3-030-00889-5_1.
- [11] Gielczyk A, Marciniak A, Tarczewska M, Lutowski Z. "Pre-processing methods in chest X-ray image classification." *Plos one* 17.4, Apr. 2022, DOI: 10.1371/journal.pone.0265949.
- [12] Forrest Iandola, Matt Moskewicz, Sergey Karayev, Ross Girshick, Trevor Darrell, and Kurt Keutzer, "Densenet: Implementing efficient convnet descriptor pyramids." arXiv, 2014 [Online]. Available: <https://arxiv.org/abs/1404.1869>.
- [13] Simonyan, Karen, and Andrew Zisserman. "Very deep convolutional networks for large-scale image recognition," arXiv, 2014 [Online]. Available: <https://arxiv.org/abs/1409.1556>.



권다운(Da-Woon Kwon)

약력

2020년~현재: 울산대학교 IT융합학부 학사과정

※관심분야: 의료 인공지능